



* Related Work

- 원래 가장 유명한 RL의 예는 TD-Gammon (value function approximation one-hidden layer의 neural-layer perception 있음)
그러나 이후 chess engine 된 이후에 RL이 주류의 reinforcement: value function을 근사하게 한 TD-Gammon의 특성은 여전히 상당히 아쉬운 점도 있음.
- DQN, multi-free RL (ex. Q-learning)도 value approximation or off-policy의 관점에서 보면 Q-network가 상당히 잘 발전했다는 게 맞다.
- 그러나, RL에는 DL의 발전이 있어 DL과 RL은 online learning 분야에 있어 중요.
한편, deep learning은 online gradient temporal-difference로 학습 가능하다.
이 때문에 final policy가 nonlinear function approximation이 될 수 있는 neural network를 linear function approximation의 관점에서 근사하게 된 것. ✓
그러나 이런 관점으로는 nonlinear network를 학습하기 위한 (유사) RL 접근이.
- 두 번째 번째 가장 유명한 RL의 예는 neural fittet Q-learning (NFOQL)이다.
NFOQL은
- RPROP 알고리즘으로 loss function을 최소화.
- 또한, 여러 개의 batch updates data set이 주어 있을 경우 batch update.
- 또한 batch update 대신 stochastic gradient update 사용.
- 또한 NFOQL은 action-value를 가진 neural low-dimensional로 만든 NFOQL 알고리즘.
- 또한, 이 예는 visual input (raw pixel)도 batch input으로 사용되고, 여러개의 층까지 결합 가능한 구조이다.
- 다른 사례

* DQN

- CVR과 동등한 인식이 반복하면서 raw input을 바로 받아서 처리할 수 있게 되었다.
DQN은 SGD에 기반한 lightweight 업데이트를 사용함.
이것이 바로 DQN의 RNN을 각 업데이트 SGD 업데이트를 위한 훈련, DQN과 RL로 전환하는 과정은 간단.
- Test-time의 TD-Gammon이 큰 장점을 보인다.
이때 value function을 근사하는 parameter를 on-policy로 업데이트함.
그런데, 이 접근이 인공적으로 학습하는 반면, human은 진짜와 같은 것을 훈련 가능, 현대 DQN과 RL로 전환하면 이러한 특징은 볼 수 있을 것임.
- 그러나, 같은 문제는 다뤄진, 한 experiment을 제공하는 상황.
experiment = (S_t, A_t, R_t, S_{t+1})
dataset = $\mathcal{D}_1, \mathcal{D}_2, \dots, \mathcal{D}_n$
- 인공은 바를 더 많은, DQN은 sample random하게 가져와 Q-learning update, stochastic update를 제공한다.
이 다른 update는 ϵ -greedy로 여러 action을 한다.
또한, update를 여러 history를 사용함. 진짜 game에서는 Q function이 여러 개의 action을
(여러 history) (한 game의 final score) 사용함.

Algorithm 1 Deep Q-learning with Experience Replay

```

Initialize replay memory  $\mathcal{D}$  to capacity  $N$ 
Initialize action-value function  $Q$  with random weights
for episode = 1, 2, 3, 4, 5 do
    Initialize sequence  $s_1 = (x_1)$  and preprocessed sequence  $\phi_1 = \phi(x_1)$ 
    for  $t = 1, 2, 3, 4, 5$  do
        With probability  $\epsilon$  select a random action  $a_t$ 
        otherwise select  $a_t = \arg \max_a Q(s_t, a)$  in  $\mathcal{D}$ 
        Execute action  $a_t$  in environment and observe reward  $r_{t+1}$  and image  $s_{t+1}$ 
        Set  $\phi_{t+1} = \phi(s_{t+1})$  and preprocessed  $\phi_{t+1} = \phi(s_{t+1})$ 
        Store transition  $(s_t, a_t, r_t, \phi_{t+1})$  in  $\mathcal{D}$ 
        Sample random minibatch of transitions  $(s_i, a_i, r_i, \phi_{i+1})$  from  $\mathcal{D}$ 
        Set  $y_i = \begin{cases} r_i + \gamma \max_{a'} Q(s_{i+1}, a') & \text{for terminal } s_{i+1} \\ r_i + \gamma Q(s_i, a_i) & \text{for non-terminal } s_{i+1} \end{cases}$ 
        Perform a gradient descent step on  $\|y_i - Q(s_i, a_i)\|^2$  according to equation 3
    end for
end for

```

- 장점 1. 모든 sample의 experience가 다같이 업데이트 될 수 있음. data efficiency 좋음.
- 장점 2. 랜덤한 sample를 제공하는 sampler가 랜덤한 memory를 많이 가져옴.
그러나, 많은 experience를 가져와도 random하게 가져 오는 게 훨씬 낫다.
- 장점 3. Off-policy 학습.
Data distribution이 바뀐 경우에도 변화가 없다.
On-policy에, 그러나, off-policy는 data를 잘라내고, 학습하게 하면서, final parameter는 다져서 diverge를 줄임.
- 한계점.
한편, 반복적인 학습은 사적인 experience를 제공하고, update가 random하게 가져옴.
이것이 중요한 것은 적절하게 학습이 된다.
또한, 랜덤한 action sampling은 학습을 many episode에 걸쳐서 이루어지므로, 학습이 느리다.

* Preprocessing & Model Architecture.

